國立屏東大學

資訊工程學系

實務專題報告書

線上手寫中文字辨識

專題學生: 林正文 CBB104061

楊舜驛 CBB104034

指導教授: 董呈煌 教授

Project Proposal

Department of Computer Science and Information Engineering,
National Pingtung University
Pingtung, Taiwan
JUNE, 2018

中華民國 107 年 12 月

摘要

本專題主要是針對手寫中文字的即時識別系統進行研究,目的是為開發一套方便實用,且能有效改善市面上之辨識系統無法成功辨識之問題。以5399種常用中文字為範圍,每類皆挑選出一個樣本字,再來其餘的字用作測試的文字資料。本研究所提出之辨識方法,是以每個筆畫為單位擷取其中的三個點座標以及該筆畫與水平線之夾角作為特徵,並以建立差值表格的方式求出最佳配對。5399類中文字,共118755個測試字的辨識率為70.11%。另外,前50名的累積辨識率則為97.38%。

目錄

第一章 緒論	5
1.1 研究動機	5
1.2 研究目的	7
1.3 研究範圍與限制	8
第二章 系統架構	9
2.1 系統架構概述	9
2.2 圖形前處理	9
2.3 特徵抽取	11
2.3.1 起始點與結束點	11
2.3.2 最遠點與 r 值	11
2.3.3 角度	13
2.3.4 筆畫順序	14
2.4 辨識	14
第三章 成果展示	21
3.1 辨識率結果	21
3.2 手寫辨識程式	23
第四章 結論與未來改進	25
4.1 結論	25
4.2 未來改進	26

圖目錄

2. 1	圖一 系	· 統架構圖	9
2. 2	圖二 字	的原圖	10
2.3	圖三 正	.規化後的字	10
2.4	圖四 筆	畫起點終點示意圖	11
2.5	圖五 筆	畫最遠點示意圖	12
2.6	圖六 筆	畫線段示意圖	13
2.7	圖七 筆	畫角度示意圖	13
2.8	圖八 比	:對差值表示意圖	14
2.9	圖九 比	:對差值表示意圖(筆畫)	15
2.10	圖十 比	:對差值表示意圖(特徵)	16
2.11	圖十一	比對差值表示意圖(表格值)	18
2.12	圖十二	比對差值表示意圖(最小值)	19
2.13	圖十三	比對差值表示意圖(最終值)	20
3. 1	圖十四	樣本文字	21
3. 2	圖十五	測試文字	22
3.3	圖十六	手寫辨識程式	23

第一章 緒論

1.1 研究動機

線上手寫中文字辨識為中文字識別領域中,一項重要且 廣泛運用的技術。手寫中文字的識別一向被視為是一個不易 解決的難題,因為每個使用者,其書寫風格之變化,筆畫順 序不一,書寫方式差異大,都大大加深了辨識的難度。雖然 線上手上寫中文字辨識為圖像識別(pattern recognition) 中的一個類別,但是由於中文字的獨特性與其特徵的性質, 都導致不易直接使用當前的一般模式識別方法實現高精準 度。

在資訊化的時代,大多數人都是用電腦或手機 app 作為 通訊工具,並且多以注音或羅馬拼音輸入文字,然而對於不 善使用拼音方式輸入者,可能會產生輸入緩慢且易錯之問題。 且有部分中文字,其注音冷僻生澀,在輸入前可能還需特地 去查詢其注音才能完成輸入,不但費力且耗時。 目前的線上手寫中文字辨識技術運用的領域十分廣泛, 然而以此作為習慣輸入法之使用者卻不多,由此可見,此領 域有許多可再更精進,且讓使用者更為方便運用的技術可探 討與研究。

本專題研究由電腦程式之簡易手寫板之手寫文字為對 象,測試在每個筆畫一完成便即時進行辨識,測試各類手寫 風格,筆畫習慣等因素是否影響辨識效果和如何改進辨識效 果。

1.2 研究目的

本專題研究是讓使用者藉由手寫板書寫文字,並從文字圖形中擷取原始點座標下來,並和原有的文字樣本作比對,尋找可取用之特徵,並且測試評估特徵之效果,另外再設計合適的辨識方法。觀察即時手寫中文字的特性,選用效果良好的特徵,反覆組合測試,並在合適的辨識方法下計算辨識率,並探討筆畫順序、手寫習慣等因素是否影響辨識效果和如何改進辨識效果。

此專題系統處理流程大致分為文字樣本產生和篩選、文字圖形資料前處理、字型特徵抽取、與樣本文字辨識比對,主要這四個部分,而最後逐一辨識產生累積辨識率。文字圖形前處理主要是將文字正規化,統一大小,如此擷取的特徵才能進行合適的比對。字型特徵抽取則是將一個文字圖形,以筆畫為單位抽取數個合宜之特徵並儲存。辨識比對則是將此文字與所有遵循相同特徵抽取方式之樣本文字進行比對,找出最適當的為辨識結果。反覆透過實驗證明,此特徵之抽取與組合,套用此辨識方法是有效且實用的。

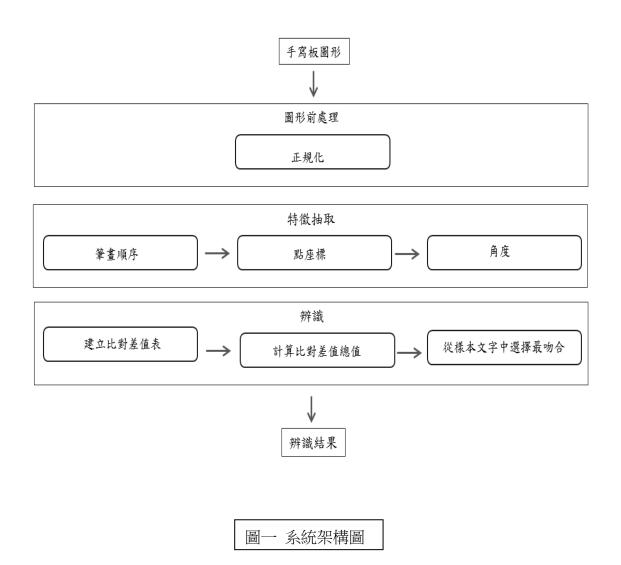
1.3 研究範圍與限制

本專題實驗讓一般使用者在電腦中的手寫板輸入單一個中文字作為辨識對象,且以 5399 種常用中文字形做為比對用的樣本文字,若寫入之文字不在樣本字之選字範圍,則無法有效辨識。

手寫中文字因每個人不同的書寫習慣、會延伸出許多值 得探討解決的問題,其中最常見的就是筆畫連筆之問題。因 中文字之繁瑣,許多人常在書寫時會求快求簡而連筆寫字, 有些甚至會一筆畫完成字,然而本專題實驗研究至目前為止 所使用之辨識方法,對於連筆問題的解決成效仍有限。另外, 筆畫反寫也是一項需解決的問題,這個部分的成效也有待觀 察。

第二章 系統架構

2.1 系統架構概述



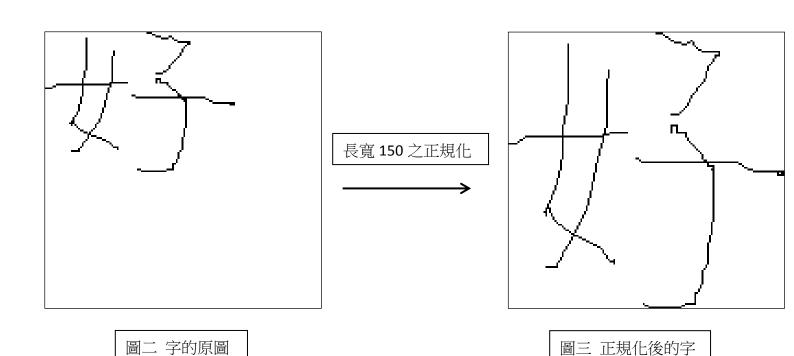
2.2 圖形前處理

本專題實驗所使用之主要特徵,必須在文字大小一致之 情況才能進行擷取。因此,對於所有寫入之文字圖形需先正 規化其大小,本實驗將字形統一至長寬 150。輸入之最原始 資料為一連串點座標,正規化之方法便是將該字所有點座標 代入以下公式:

$$(X - minX) / (maxX - minX) * 149 = X'$$

$$(Y - minY) / (maxY - minY) * 149 = Y'$$

(X,Y)為原始點座標。 minX, minY 分別為該字所有點座標中最小的 X 值與 Y 值;maxX, maxY 則分別為該字所有點座標中最大的 X 值與 Y 值。(X¹, Y¹)為正規化後點座標。

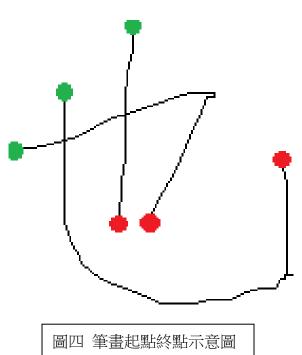


10

2.3 特徵抽取

2.3.1 起始點與結束點

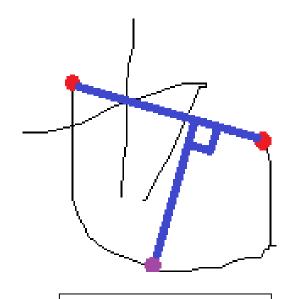
將正規化後的字,每個筆畫的起始點座標與結束點座標 紀錄,如圖四:綠色點為該筆畫之起點,紅色點為該筆畫之 終點



2.3.2 最遠點與 r 值

點座標為採用之主要特徵。除了基礎之起點與終點座標兩種座標點,另外再使用本實驗稱為最遠點的第三種座標,該座標為一個筆畫的所有點座標中,與該筆畫的起始點與結束點之線段距離最遠的點,如圖五所示。

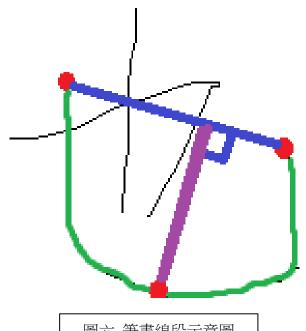
圖五中紅色兩點為起點終點,紫色點為最遠點



圖五 筆畫最遠點示意圖

最遠點座標主要功能與使用,目的為展現筆畫彎曲之特性。除了最遠點座標,還另外計算一種數值調和之,該數值本實驗稱為 r 值,為該筆畫之最遠點至起始點結束點之線段的距離長度,除以該筆畫之總長度。如圖六所示。

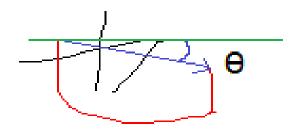
圖六中紫色線段為該筆畫最遠點至起始點結束點之線 段的距離長度(L1),綠色線段為筆畫之總長度(L2),r = L1/L2



圖六 筆畫線段示意圖

2.3.3 角度

角度特徵為筆畫起點與終點之線段至水平線夾角 之角度,其角度之範圍為+180至-179。因採用此特徵 之目的,是為展現輸入者之手寫文字之特性,且無須 統一字體大小即可進行比對,所以此特徵並不使用正 規化後之文字,而是從原始之文字進行抽取。



圖七 筆畫角度示意圖

2.3.4 筆畫順序

雖然每個人手寫中文字的書寫風格差異大,從字體大小到字形不等,但在筆畫書寫的順序上大致仍有一套通用的習慣,因此本實驗也採用筆畫之順序,為提升辨識率之輔助特徵。

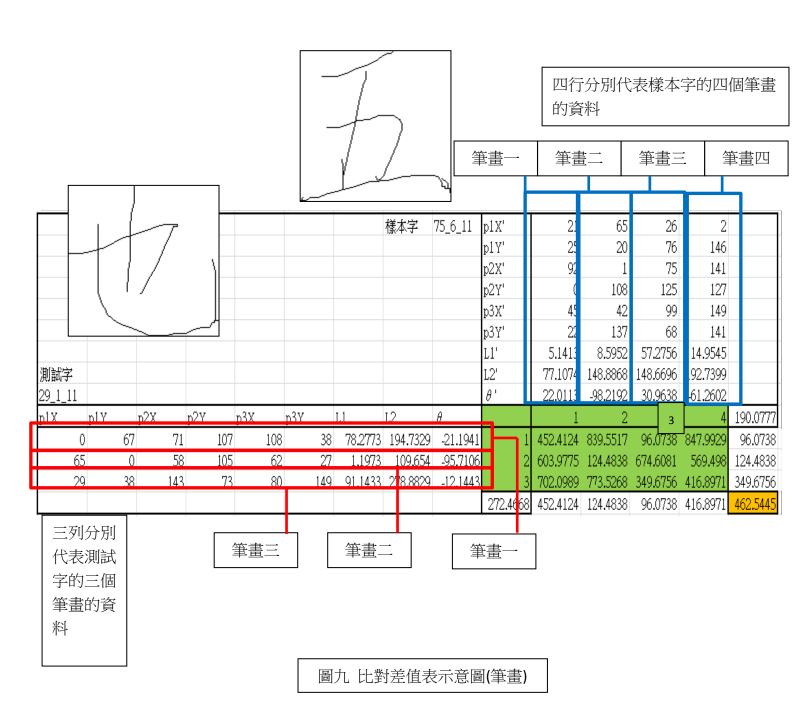
2.4 辨識

本實驗採之比對方法,是將2.3之所有特徵進行組合,並將組合完成之特徵值與同樣做法之樣本文字相減比對,並建立一個比對差值表,再從該表中產生比對的最後總值,而該字與所有樣本文字皆進行比對,比對值最小之樣本文字,便為與該字最吻合之比對字。

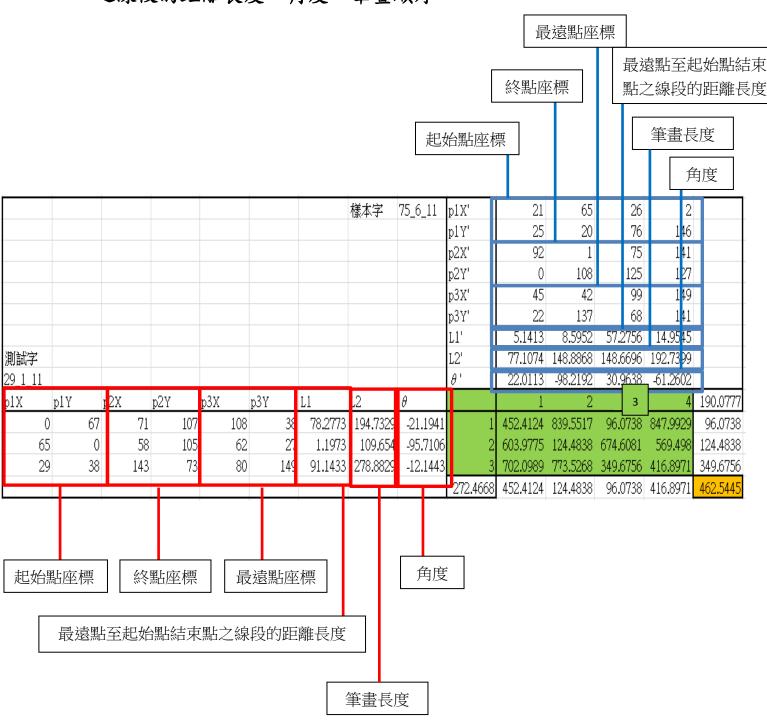
							_				- (1				
													樣本字	75_6_11	plX'	21	65	26	2	
															plY'	25	20	76	146	
															p2X'	92	1	75	141	
															p2Y'	0	108	125	127	
															р3Х'	45	42	99	149	
															p3Y'	22	137	68	141	
															L1'	5.1413	8.5952	57.2756	14.9545	
測試	学														L2'	77.1074	148.8868	148.6696	192.7399	
29_1_	.11														θ '	22.0113	-98.2192	30.9638	61.2602	
p1X		p1Y		p2X		p2Y		рЗХ		рЗҮ	I	L1	L2	θ		1	2	3	3 4	190.0777
	0		67		71		107	1	08	3	38	78.2773	194.7329	-21.1941	1	452.4124	839.5517	96.0738	847.9929	96.0738
	65		0		58		105		62	2	27	1.1973	109.654	-95.7106	2	603.9775	124.4838	674.6081	569.498	124.4838
	29		38		143		73		80	14	9	91.1433	278.8829	-12.1443	3	702.0989	773.5268	349.6756	416.8971	349.6756
															272.4668	452.4124	124.4838	96.0738	416.8971	462.5445

圖八 比對差值表示意圖

以下為一例兩字相互比對的例子,選用三筆畫的字作為 測試字,並以四筆畫的樣本字,兩字皆做前處理完畢,取好 特徵,並比對計算產生比對差值表。



分別以每個筆畫為單位,所擷取之特徵依序為起點座標、 終點座標、最遠點座標、筆畫長度、最遠點至起始點結束點 之線段的距離長度、角度、筆畫順序。



圖十 比對差值表示意圖(特徵)

圖十一的綠色表格中每一格數值皆是用以下公式計算產生: (起點位移差+終點位移差+最遠點位移差*(r值差值)* α)* 角度差值 *筆畫順序差值

此公式是本專題經研究,疊加或刪減許多特徵,並探討每個特徵之作用與影響性組合而成之公式,而公式中用以放大或縮小特徵的參數,也是經反覆實驗細微調整後所訂定,用以搭配找出辨識效果最為顯著之方法。以圖十一為例,細探其公式之計算:

起點位移差:sqrt((p1X-p1X')^2+ (p1Y-p1Y')^2)

終點位移差:sqrt((p2X-p2X')^2+ (p2Y-p2Y')^2)

最遠點位移差:sqrt((p3X-p3X')^2+ (p3Y-p3Y')^2)

r 值差值:abs(L1/L2 - L1'/L2')

α值:5

β值:75

角度差值:1+abs(θ - θ ')/ β

筆畫順序差值:1+abs(當前筆畫/總筆畫數-當前筆畫[']/總筆畫數')

另外,在計算角度差值時須特別注意,角度相減完取絕對值, 若該值大於 180°則需用 360°再減該值,取其銳角部分。 起點位移差: sqrt((0-21)^2+(67-25)^2) = 46.96 終點位移差: sqrt((71-92)^2+(107-0)^2) =109.04

最遠點位移差: sqrt((108-45)^2+(38-22)^2) = 65

r 值差值:abs(78.2773/194.7329 - 5.1413/77.1074)=0.3353

 α =5

 β =75

角度差值:1+abs(-21.1941-22.0113)/ β=1.5761

筆畫順序差值:1+abs(1/3-1/4)=1.0833

(起點位移差+終點位移差+最遠點位移差*(r 值差值)* α)*角度差值 *筆畫順序差值

=(46.96 + 109.04 + 65*0.3353*5)*1.5761*1.0833

=264.9725*1.5761*1.0833

=452.41

												樣本字	75_6_11	p1 K '		21	65	26	2	
														1/r1q		25	20	76	146	
														p2X		92	1	75	141	
														p2Y'		0	108	125	127	
														р3Х'		45	42	99	149	
														p3Y'	\	22	137	68	141	
														L1'	Λ	5.1413	8.5952	57.2756	14.9545	
測試得	Z													L2'	$-$ \	77.1074	148.8868	148.6696	192.7399	
29_1_	11													θ '	N	22.0113	-98.2192	30,0639	-61.2602	
p1X	ŗ	p1Y	p2X		p2Y		рЗХ		рЗҮ		L1	L2	θ			1	2	3	4	190.0777
	0	6	7	71		107		108		38	78.2773	194.7329	-21.1941		1	452.4124	839.5517	96.0738	847.9929	96.0738
	65		0	58		105		62		27	1.1973	109.654	-95.7106		2	603.9775	124.4838	674.6081	569.498	124.4838
	29	3	3	143		73		80		149	91.1433	278.8829	-12.1443		3	702.0989	773.5268	349.6756	416.8971	349.6756
														272.4	668	452.4124	124.4838	96.0738	416.8971	462.5445

圖十一 比對差值表示意圖(表格值)

在計算完成綠色表格中的所有數值後,接著再分別以行列為 單位,找出該行該列中最小的數值,此目的是用以找出兩字 之間,其筆畫的最佳配對。

> 此列最小數值為 349.6756,是測試字第 三筆畫與樣本字第三筆畫的比對結果 代表測試字的第三個筆畫在與樣本字所 有筆畫的比對中,是與樣本字第三個筆 畫最為吻合

													樣本字	75_6_11	p1X'	21	65	26	2		
															p1Y'	25	20	76	146	1	
															p2X'	92	1	75	141		
															p2Y'	0	108	125	127		
															p3X'	45	42	99	149		
															p3Y'	22	137	68	141		
															L1'	5.1413	8.5952	57.2756	14.9545	- 1	
測試	字														L2'	77.1074	148.8868	148.6696	192.7399	-\	
29_1_	11														θ '	22.0113	-98.2192	30,0620	-61.2602		
p1X		p1Y		p2X		p2Y		р3Х		рЗҮ		L1	L2	θ		1	2	3	4	190	0777
	0		67		71		107		108		38	78.2773	194.7329	-21.1941	1	452.4124	839.5517	96.0738	847.9929	96	. 0738
	65		0		58		105		62		27	1.1973	109.654	-95.7106	2	603.9775	124.4838	674.6081	569.498	124	.4838
	29		38		143		73		80		149	91.1433	278.8829	-12.1443	3	702.0989	773,5268	349.6756	416.8971	349	.6756
															272.4668	452.4124	124.4838	96.0738	416.8971	462	.5445

此行最小數值為 452.4124,是測試字第一筆畫與樣本字第一筆畫的比對結果 代表測試字的第一個筆畫在與樣本字所 有筆畫的比對中,是與樣本字第一個筆 畫最為吻合

圖十二 比對差值表示意圖(最小值)

最後,將分別找出的最小值加總計算平均,再將行列之結果 相加,得出之值則為此兩字的最終比對結果數值。

將每一列找出的最 小數值加總平均, 得出:190.0777

_																				
													樣本字	75_6_11	p1X'	21	65	26	2	
															plY'	25	20	76	146	
															p2X'	92	1	75	141	
															p2Y'	0	108	125	127	
															p3X'	45	42	99	149	
															p3Y'	22	137	68	141	
															L1'	5.1413	8.5952	57.2756	14.9545	
測試	字														L2'	77.1074	148.8868	148.6696	192.7399	
29_1_	11														θ '	22.0113	-98.2192	30 <u>,9638</u>	-61.2602	
p1X		p1Y	p.	2X]	p2Y		p3X		рЗҮ		L1	L2	θ		1	2	3	4	190.0777
	0		67	-	71		107		108		38	78.2773	194.7329	-21.1941	1	452.4124	839.5517	96.0738	847.9929	96.0738
	65		0		58		105		62		27	1.1973	109.654	-95.7106	2	603.9775	124.4838	674.6081	569.498	124.4838
	29		38	14	13		73		80		149	91.1433	278.8829	-12.1443	3	702.0989	773.5268	349.6756	416.8971	349.6756
															272.4668	452.4124	124.4838	96.0738	416.8971	462.5445

將每一行所找出的最小數值加 總平均,得出 272.4668

最後再將行列的最小值平均值 加總,此值便為這兩字比對後 的最終結果值

272.4669 + 190.0777 = 462.54

圖十三 比對差值表示意圖(最終值)

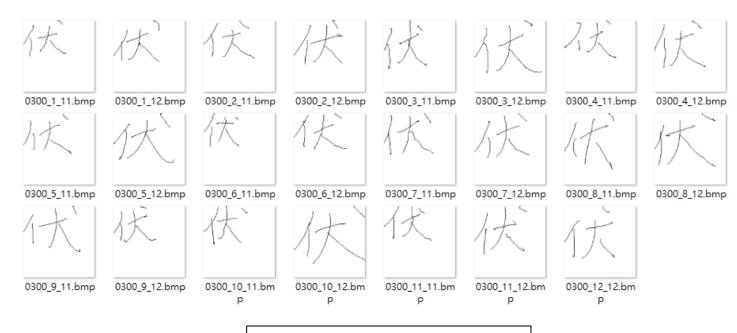
第三章 成果展示

3.1 辨識率結果

本專題之實驗是以 5399 種常用中文字為範圍。首先在字庫中針對每一類的字,從中挑選較為標準美觀的字做為該類的樣本字,如圖十四所示。接著在每一類字形中把剩下來約二十幾種經由不同人所寫的字形作為測試文字,如圖十五所示。樣本文字數量為 5399 個,測試文字數量為 118755 個。



圖十四 樣本文字

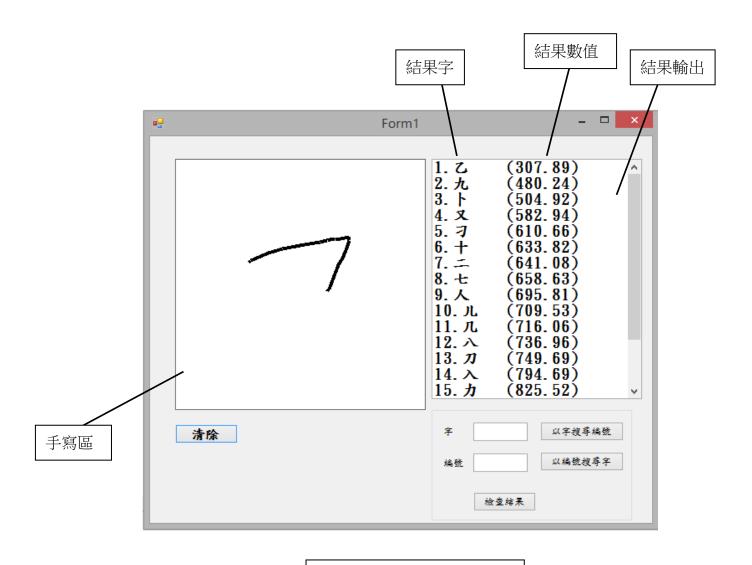


圖十五 測試文字(第300類 伏)

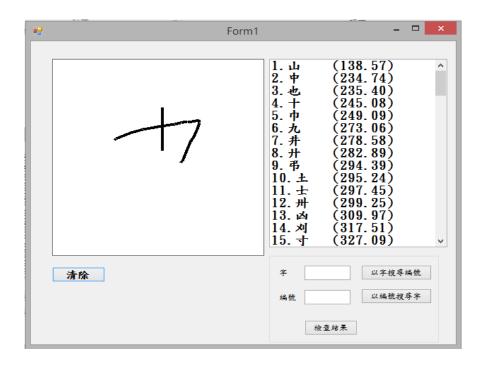
經反覆實驗疊加擷取之特徵與探討其運用之成效,測試公式中用以調和特徵的係數,以求其效果最顯著之值,本專題所提出之辨識方法可讓 118755 個測試文字中,有 83259 個字成功命中其所屬類別之樣本字,也就是約有 70.11 %的辨識率。另外,前 50 名的累積辨識率也有達至 97.38 %。

3.2 手寫辨識程式

以下為將實驗之結果寫成一個測試用之手寫板。在手寫 區寫入文字,每當一個筆畫結束,便會立刻進行辨識,並將 結果輸出再右側之顯示板上。



圖十六 手寫辨識程式(1)



圖十六 手寫辨識程式(2)



圖十六 手寫辨識程式(3)

第四章 結論與未來改進

4.1 結論

現代資訊發展極為迅速,絕大多數的人都是以手機通訊 作為主要的溝通方式,而其中又以注音拼寫為多數的輸入方 式,相較之下,手機中的手寫辨識功能雖已完備,但以此作 為主要輸入習慣者卻相當少數,其中的原因相當值得探討, 速度上較為緩慢,輸入時較為繁瑣,又或是辨識的成效仍有 些許不足,仍有許多可再探討與改善的部分。資訊化輸入資 料已是最為主流的書寫方式,要如何使這個領域可使用的技 術更為完善便利,是很值得再繼續深入研究的。

雖然現在有許多成熟的手寫辨識系統,但對於某些文字 或手寫習慣仍常出現辨識錯誤的情形,最常見莫過於連筆問題,如何徹底改進辨識連筆字將是一大探討的方向。另外, 在現在之基礎上如何再提升辨識率也是一大問題,字過於歪 斜不規則而導致的辨識錯誤,如何調整取用的特徵或辨識方 法去應對,都是非常需要再加強改進的部分。

4.2 未來改進

在未來改進上,針對辨識率的提升與實際應用,大致可以在數個部份上做努力,期許能得到更好的結果。第一就是持續探討如何提升辨識率, 針對個案深入細看其特點,再找出發想可以加入或是加強的特徵。第二是對於筆畫反寫的問題,目前是已提出一個解決的方案,可以持續找出例子觀察該方案的成效,評估是否要再加強,第三則是對連筆問題要設計可以有效應對的辦法,可以試著切割筆畫或再從其他地方著手。最後是要把此專題的實驗成果實作至行動裝置上,因目前仍是用電腦作為測試工具,但手寫辨識最為重要的還是在手機、平板電腦等應用,也因此如何實裝在行動裝置上也是未來需要探討的一環。

参考文獻

- (1) Otsu, "A threshold selection method from gray level histogram," IEEE Trans. On Systems, Man, and Cybernetics, SMC-8, 1978
- (2) http://atlaboratary.blogspot.tw/2013/08/rgb-g-rey-l-gray-r0.html
- (3) 維基百科 Wikipedia
- (4) 樂美邑,(2017). 相機取像之中文字辨識研究. 碩士論文, 國立聯合大學
- (5) 張傑閔,(2017) 離線手寫校正辨識系統. 國立屏東大學